

Apresentação da disciplina

ESTAT0016 – Tópicos Especiais em Estatística (Introdução à Aprendizagem de Máquina)

Prof. Dr. Sadraque E.F. Lucena

Informações

- Grupo no WhatsApp:



- Material das aulas: <http://tiny.cc/TopEspESTAT>
- Contato por e-mail: sadraquelucena@academico.ufs.br

Ementa

- Pré-processamento de dados.
- Aprendizado supervisionado.
- Regressão.
- Classificação.
- k -Nearest Neighbors.
- Naïve Bayes.
- Árvores de Decisão.
- Florestas aleatórias.
- Avaliação de desempenho.
- Validação Cruzada.
- Métricas de desempenho de Classificação.
- Ajuste de parâmetros.
- Bagging, Boosting e Stacking.
- Aprendizado não supervisionado.
- Regras de Associação.
- k -means.

Datas Importantes

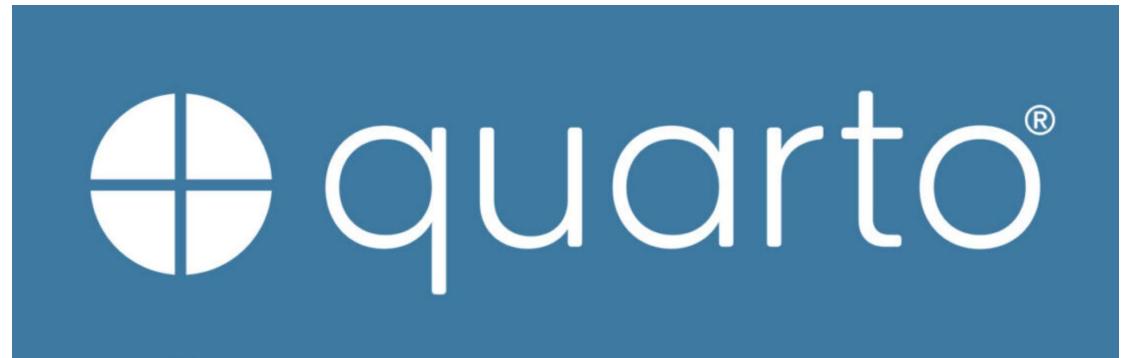
Avaliações

-

Não haverá aula

- **27 e 30/11/2023:** IX SEMAC
- **25 e 28/12/2023:** Recesso natalino
- **01/01/2024:** Confraternização Universal (feriado nacional)
- **04, 08 e 11/01/2024:** Férias coletivas para docentes
- **12/02/2024:** Carnaval
- **15/02/2024:** Não haverá aula
- **28/03/2024:** Quinta-feira Santa (ponto facultativo)

Ferramentas



Biliografia Recomendada

- FACELI, Katti. **Inteligência artificial: uma abordagem de aprendizado de máquina.** Rio de Janeiro: LTC, 2011. 378 p.
- IZBICKI, Rafael; DOS SANTOS, Tiago Mendonça. **Aprendizado de máquina: uma abordagem estatística** [livro eletrônico]. São Carlos: Rafael Izbicki, 2020.
- NWANGANGA, Fred; CHAPPLE, Mike. **Practical machine learning in R.** Indianapolis: John Wiley & Sons, 2020.
- ABU-MOSTAFA, Yaser S.; MAGDON-ISMAIL, Malik; LIN, Hsuan-Tien. **Learning from data.** New York: AMLBook, 2012.
- HASTIE, Trevor et al. **The elements of statistical learning: data mining, inference, and prediction.** New York: Springer, 2009.
- LANTZ, Brett. **Machine learning with R: expert techniques for predictive modeling.** Packt publishing ltd, 2019.

O que é apredizagem de máquina?

Descobrindo conhecimento a partir dos dados

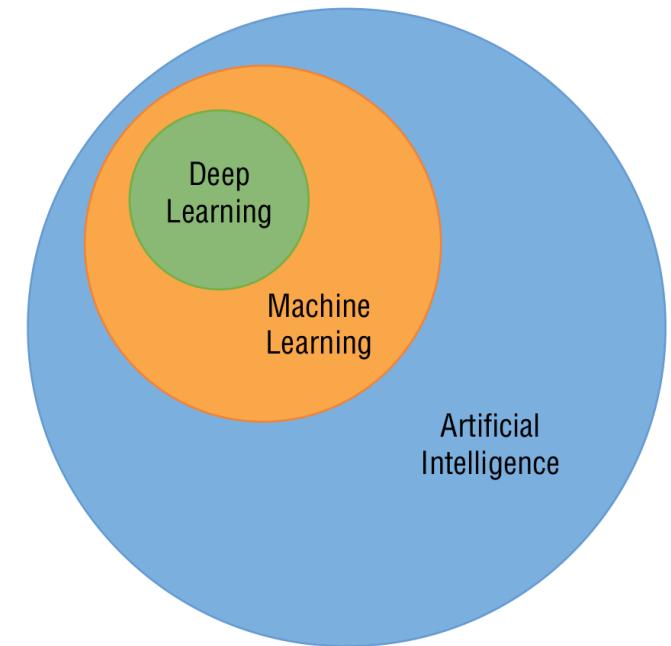
- O objetivo da aprendizagem de máquina (o inglês, *machine learning*) é **utilizar algoritmos para descobrir conhecimento a partir de conjuntos de dados** para ajudar a tomada de decisões.
- Casos em que a aprendizagem de máquina geralmente agrega valor:
 - Descobrir anomalias em registros de sistema e aplicativos que podem indicar um incidente de cibersegurança;
 - Prever as vendas de produtos com base nas condições de mercado e ambientais;
 - Recomendar o próximo filme que um cliente pode querer assistir com base em sua atividade passada e nas preferências de clientes semelhantes;
 - Definir os preços dos quartos de hotel com bastante antecedência com base na demanda prevista.

Algoritmos

- Na ciência de dados as técnicas de aprendizagem de máquina são chamadas de **algoritmos**.
 - Um algoritmo é um conjunto de etapas que são seguidas para realizar um processo.
- Outros termos também usados:
 - **métodos**
 - **modelos**
 - **técnicas**

Inteligência artificial, Aprendizagem de máquina e Aprendizagem profunda

- **Inteligência artificial (IA):** (*artificial intelligence - AI*) qualquer técnica que faz sistemas computacionais se comportarem artificialmente como se fossem inteligentes.
- **Aprendizagem de máquina:** (*machine learning*) subconjunto de técnicas de inteligência artificial que tentam aplicar estatísticas a problemas de dados na tentativa de descobrir conhecimento a partir de dados.
- **Aprendizagem profunda:** (*deep learning*) subdivisão avançada da aprendizagem de máquina que utiliza redes neurais para análise de imagens, vídeo e áudio.



Fonte: NWANGANGA & CHAPPLE, 2020

Termos usado na área

- **Instância:** representa uma unidade amostral ou indivíduo. Uma instância é caracterizada por um conjunto de atributos ou características que a descrevem. Um conjunto de dados é composto por várias instâncias.
 - **Sinônimos:** registro, exemplo, observação.
- **Atributo:** propriedade ou característica de uma instância. Cada instância é composta por vários atributos, que podem ser discretos ou contínuos.
 - **Sinônimos:** variável, característica.

Tipos de aprendizagem de máquina

- **Aprendizagem supervisionada:** o algoritmo é alimentado com dados de entrada acompanhados de respostas desejadas (rótulos). O objetivo é aprender uma função que relate esses dados de entrada às saídas desejadas usando o conjunto de treinamento como exemplos.
- **Aprendizagem não supervisionada:** o algoritmo é alimentado com um conjunto de dados de entrada que não possui rótulos ou respostas desejadas associadas. O objetivo do aprendizado não supervisionado é o algoritmo descobrir padrões, estruturas ou grupos nos dados por conta própria.
- **Aprendizagem por reforço:** envolve um agente que interage com um ambiente e toma ações para maximizar uma recompensa ao longo do tempo. O agente aprende por tentativa e erro, ajustando suas ações com base nas recompensas recebidas.

Aprendizagem supervisionada

- Um algoritmo de aprendizagem supervisionada recebe um conjunto de treinamento como entrada em que já se sabe as respostas e usa esses dados para desenvolver um modelo que busca prever ou classificar novos dados sem respostas.
- **Exemplos:**
 - Detecção de fraudes em transações financeiras.
 - Classificação de e-mails em “spam” ou “não spam”.
 - Diagnóstico médico por imagem.

Aprendizagem não supervisionada

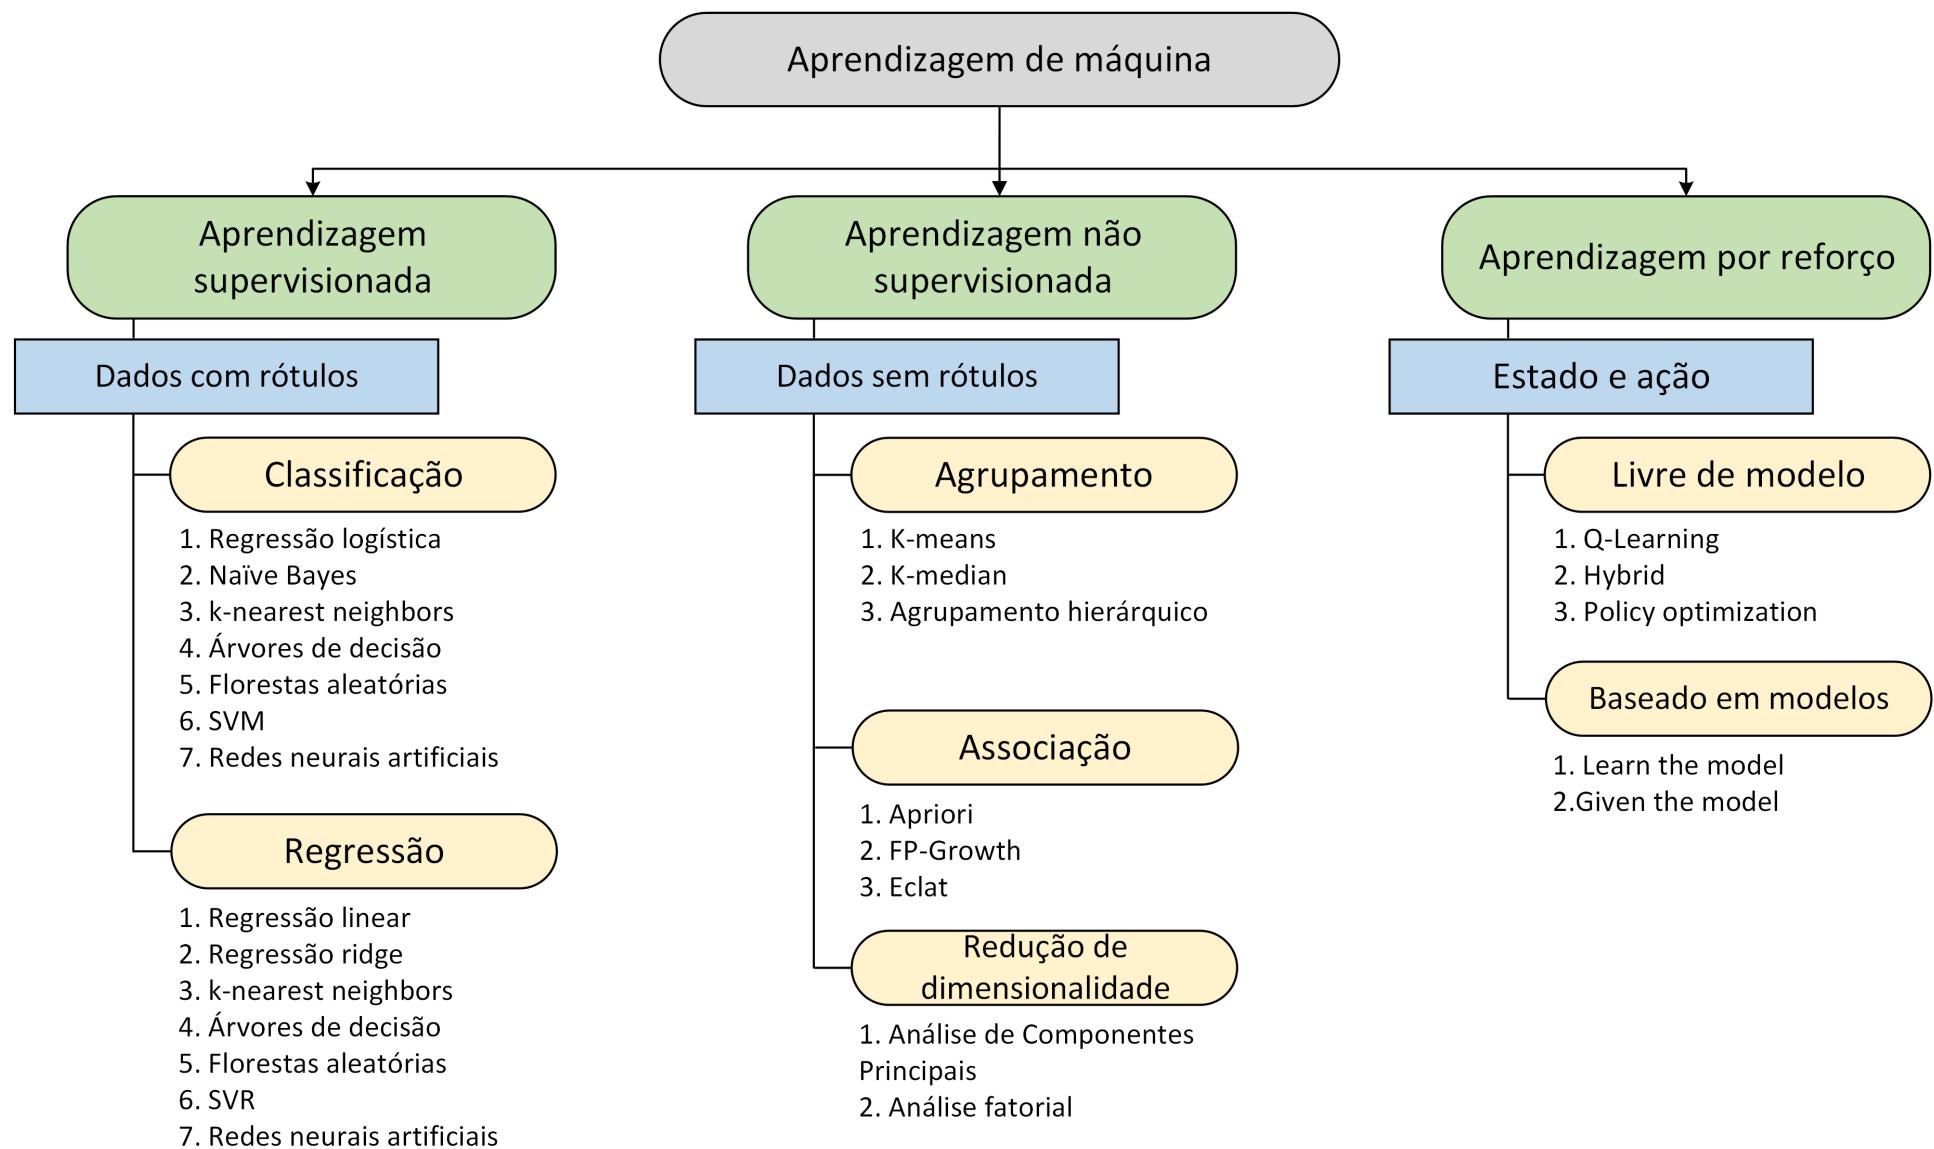
- Algoritmos de aprendizagem não supervisionada analisam dados que não possuem respostas conhecidas e procuram identificar padrões ou estruturas escondidas nos dados por conta própria.
- **Exemplos:**
 - Recomendação de produtos em comércio eletrônico a partir do agrupamento de clientes com perfis semelhantes.
 - Análise de dados de sensores ambientais para identificar padrões de poluição, variações climáticas e outros eventos de interesse.

Aprendizagem por reforço

- O algoritmo tem a capacidade de interagir com o ambiente, experimentando diversas ações e decisões para determinar aquelas que proporcionam os melhores resultados.
- Por meio de tentativa e erro, o algoritmo adquire a habilidade de identificar as abordagens mais eficazes para realizar uma tarefa.
- **Exemplos:**
 - Treinar robôs aspiradores para mapear e limpar residências
 - Fornecer conteúdo personalizado em plataformas de mídias sociais com base nas preferências e interações do usuário.
 - Treinar agentes virtuais para jogar xadrez.
- Nesta disciplina vamos nos ater a aprendizagem supervisionada e não supervisionada.

Tipos de abordagem

- **Classificação:** modelos usados para prever categorias. Exemplos:
 - Identificar se um e-mail é “spam” ou “não spam”.
 - Classificar pacientes pelo risco de saúde como “baixo risco”, “médio risco” e “alto risco”.
- **Régressão:** modelos usados para prever valores numéricos. Exemplos:
 - Previsão de preços de imóveis.
 - Previsão de venda de produtos.
- **Aprendizado por similaridade:** modelos que buscam agrupar instâncias em um conjunto de dados.
 - Agrupamento de clientes em com base em comportamentos de compra semelhantes, permitindo campanhas de marketing direcionadas.
 - Recomendação de filmes ou música com base nas preferências de outros usuários com gostos semelhantes.



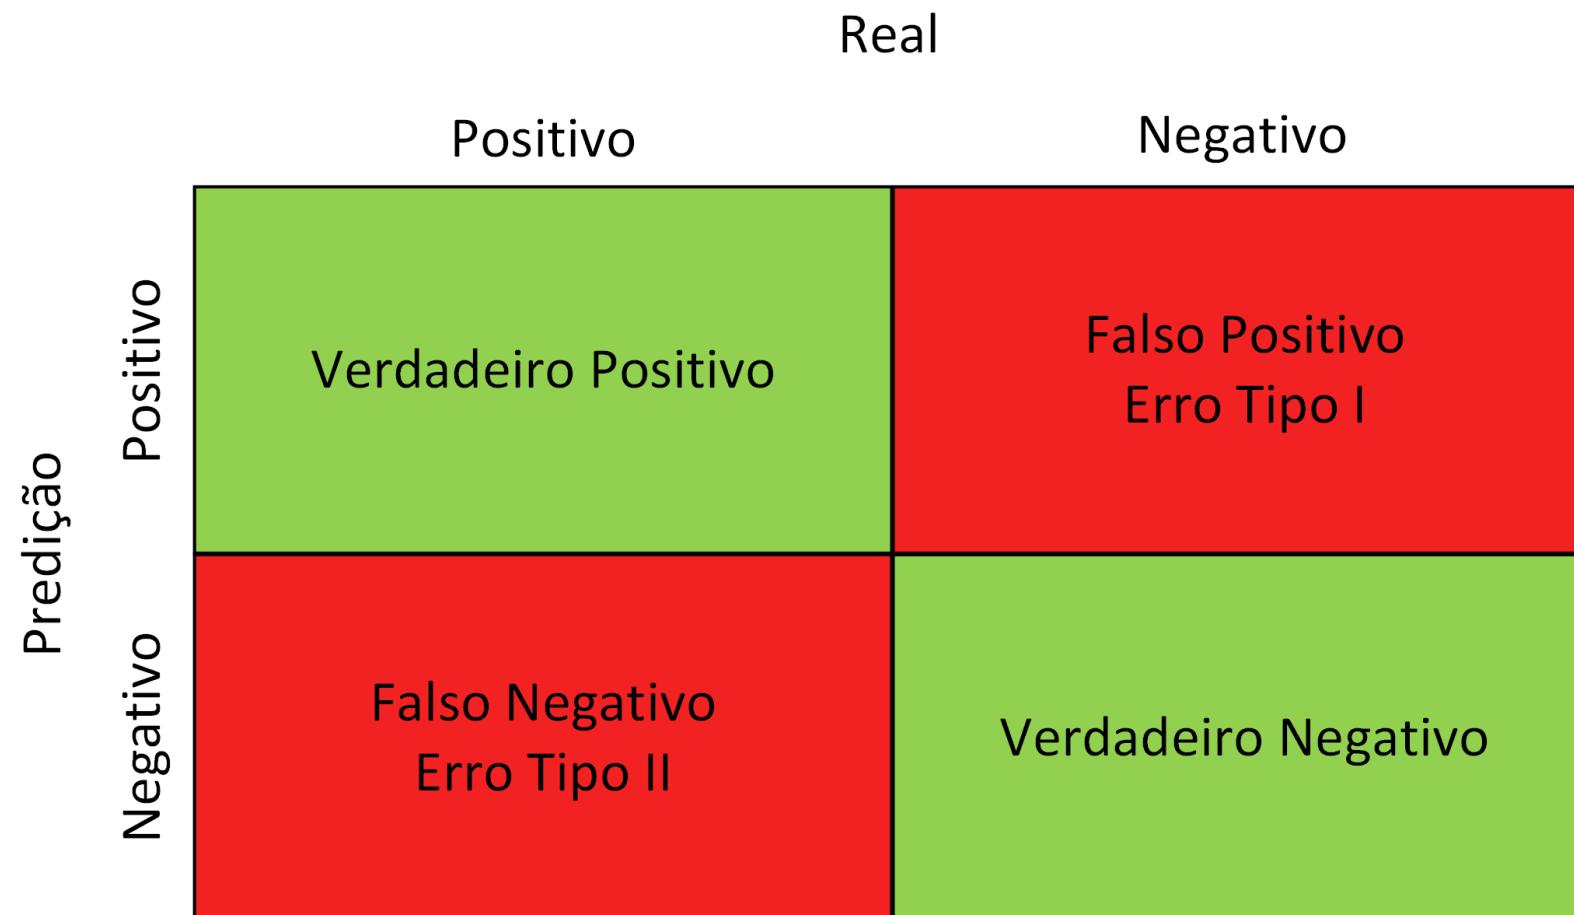
Avaliação dos modelos

- A natureza dos dados e a natureza do algoritmo define a técnica aproriada aos dados.
- Na **aprendizagem supervisionada** a eficácia de um algoritmo é avaliada com base no número e/ou magnitude dos erros que ele comete.
 - Para problemas de **classificação**, frequentemente observamos a taxa de classificação coreta ou incorreta.
 - Para problemas de **regressão** observamos a diferença entre os valores previstos pelo algoritmo e os valores reais.

Erros de classificação

- Suponha que uma observação é classificada como positiva se pertence a uma classe ou classificada como negativa se pertence a outra classe.
- Há dois tipos de erros que podem ocorrer em problemas de classificação:
 - **Falsos positivos:** quando o modelo classifica uma observação como positiva quando, na realidade, é negativa (erro tipo I).
 - **Falsos negativos:** quando o modelo classifica uma observação como negativa quando, na realidade, é positiva (erro tipo II).
- Também podemos classificar uma observação como **verdadeiro positivo** ou **verdadeiro negativo** dependendo da classificação que o modelo fez.

Tipos de erro em classificação



Fonte: Adaptado de NWANGANGA & CHAPPLE (2020)

Tipos de erro em classificação

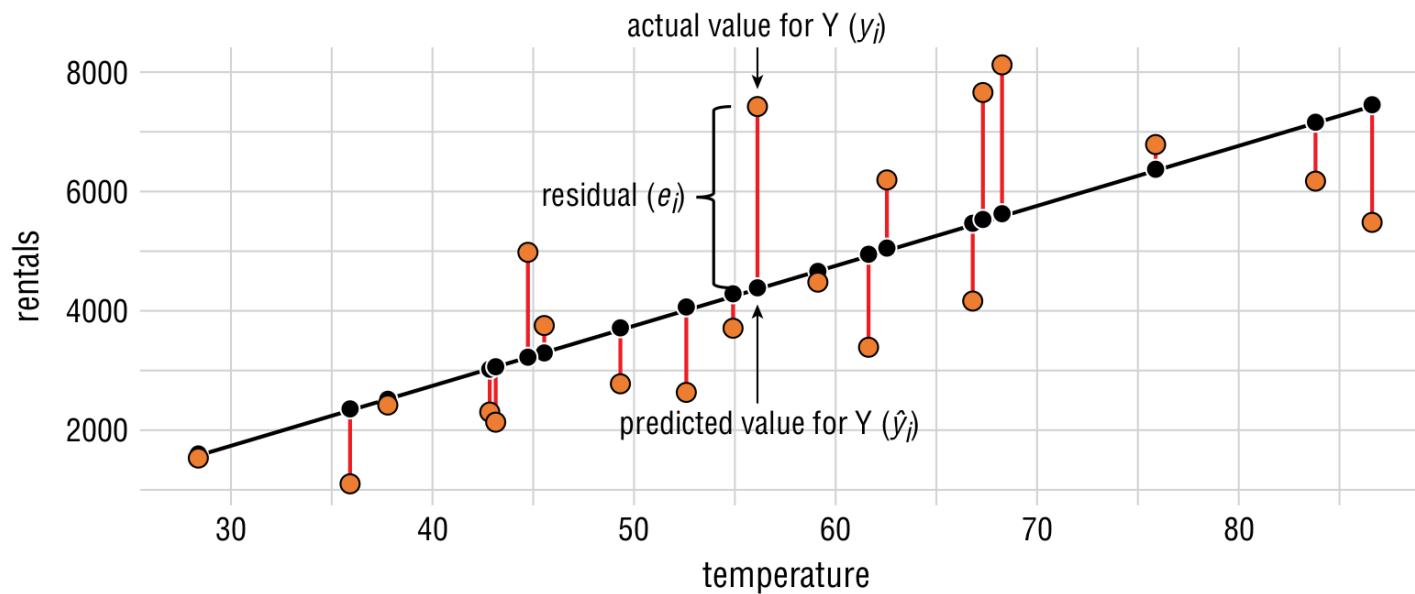
- Algumas das métricas que costumamos usar para avaliação de modelos de classificação são
 - **Taxa de falsos positivos (TFP)**: percentagem de instâncias classificadas incorretamente como positivas.
 - **Taxa de falsos negativos (TFN)**: percentagem de instâncias classificadas incorretamente como negativas.

$$TFP = \frac{FP}{FP + VN} \qquad TFN = \frac{FN}{FN + VP}$$

- FP: falso positivo
- VP: verdadeiro positivo
- FN: falso negativo
- VN: verdadeiro negativo

Erros de regressão

- Em problemas de regressão avaliamos os modelos baseado na distância entre o valor predito e o valor real.



Fonte: NWANGANGA & CHAPPLE (2020)

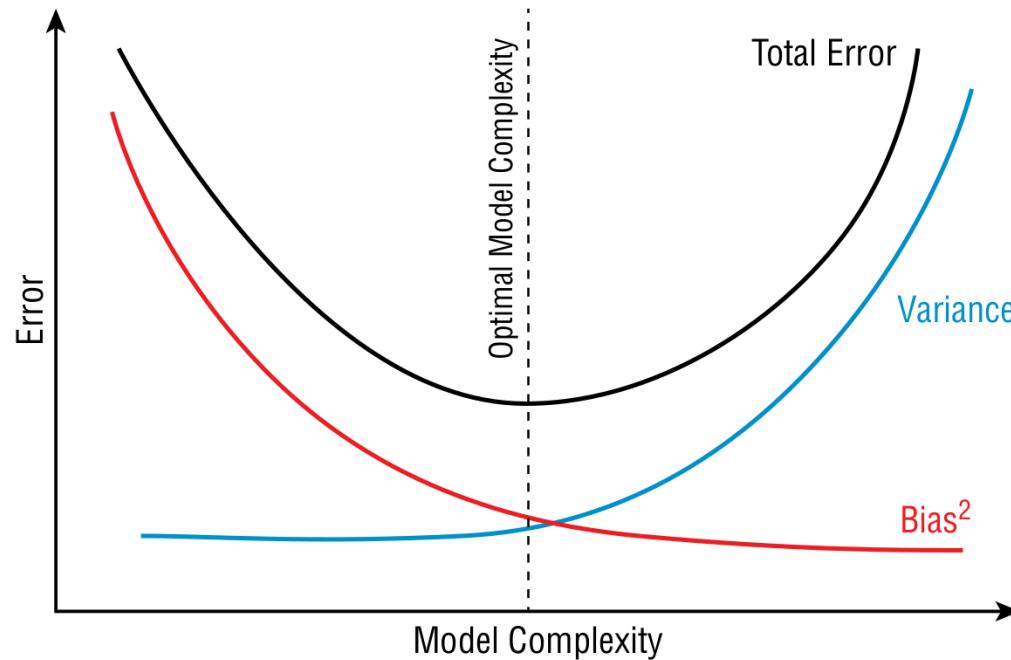
- Podemos usar a **soma do quadrado dos resíduos** para compararmos os modelos.

Tipos de Erro de predição em modelos de aprendizado de máquina

- **Viés:** ocorre quando o modelo de aprendizado de máquina escolhido não se ajusta bem ao conjunto de dados, resultando em viés.
- **Variância:** erro causado por dados de treinamento que não representam completamente o universo de possíveis dados, tornando o modelo sensível a pequenas variações nos dados de treinamento.
- **Erro Irreduzível (ou ruído):** é inerente ao problema que tentamos resolver e independe do algoritmo de aprendizado de máquina e do conjunto de dados de treinamento. Não pode ser eliminado.

Tipos de Erro de predição em modelos de aprendizado de máquina

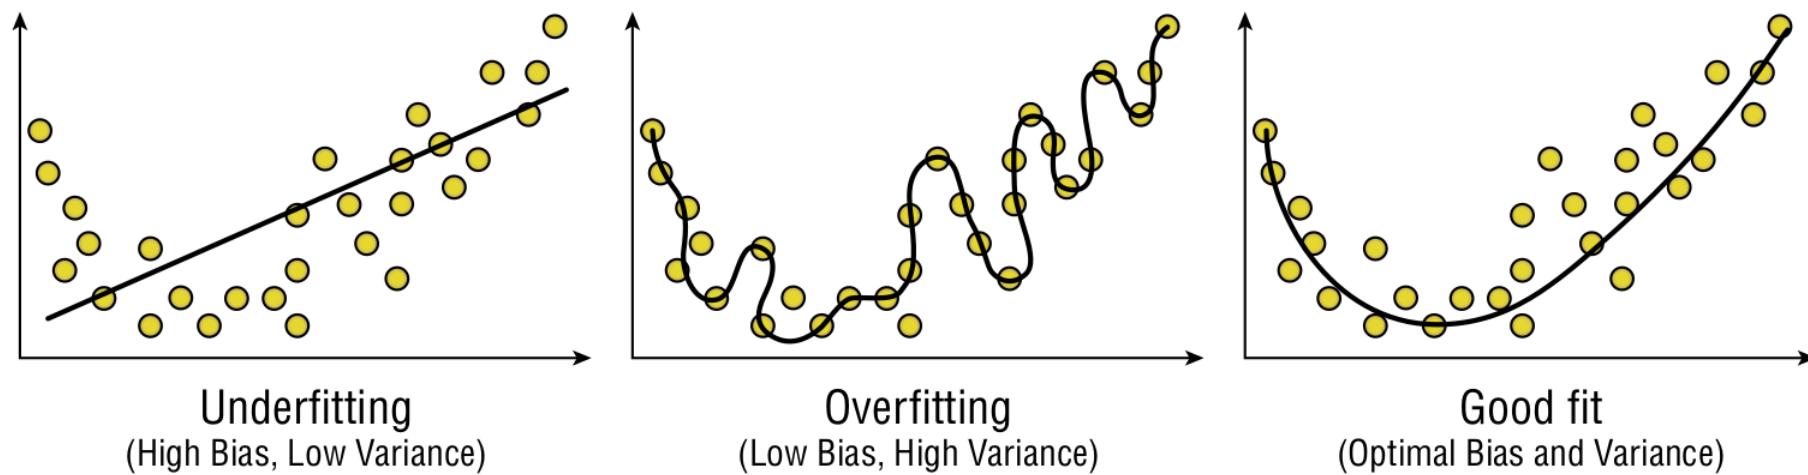
- Um algoritmo com alta variância tem baixo viés, enquanto um algoritmo com baixa variância tem alto viés. Nosso objetivo é encontrar o equilíbrio ótimo entre os dois.



Fonte: NWANGANGA & CHAPPLE (2020)

Tipos de Erro de predição em modelos de aprendizado de máquina

- Um modelo com alto viés e baixa variância é dito subajustado (*underfitted model*).
- Quando o modelo tem baixo viés e alta variância é dito sobreajustado (*overfitted model*). Nesse caso o modelo se ajustou demais aos dados de treinamento.



Fonte: NWANGANGA & CHAPPLE (2020)

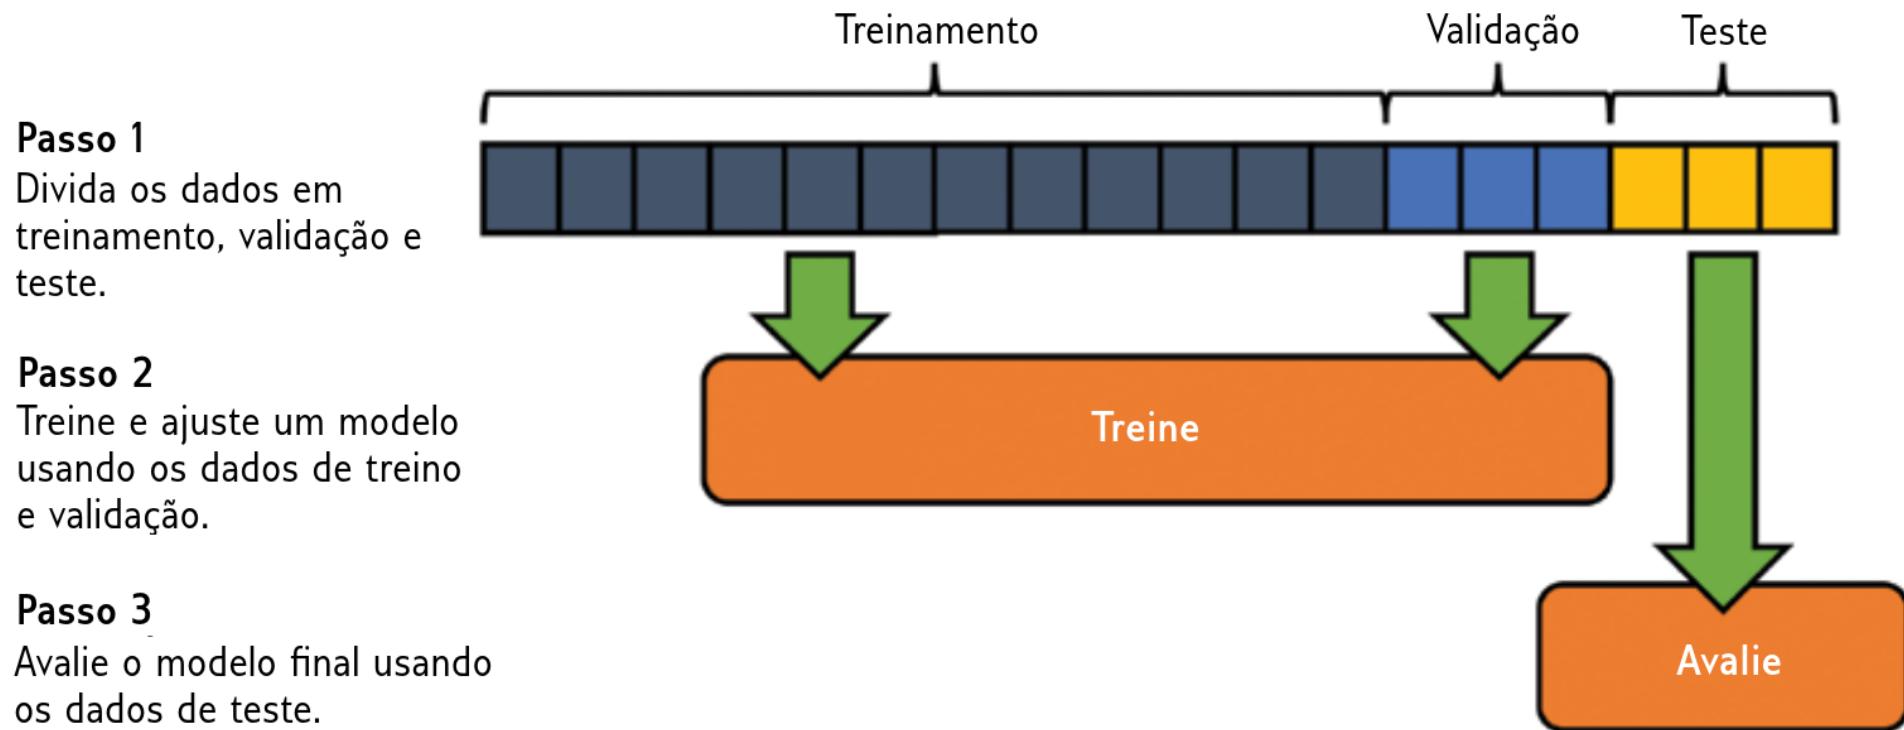
Partição dos dados

- Para determinar se os modelos de aprendizado de máquina estão sofrendo de superajuste aos dados, é essencial avaliar seu desempenho em conjuntos de dados que não foram utilizados no processo de treinamento.
- Em geral dividimos o conjunto de dados no seguinte:
 - **Dados de treinamento:** dados usados para treinar (ensinar) o modelo.
 - **Dados de teste:** dados usados para avaliar a performance do modelo. Esses dados não foram usados no treino.
 - **Dados de validação:** dados separados usados para ajustar iterativamente os parâmetros de um modelo de aprendizado de máquina, com o objetivo de encontrar a configuração que funciona melhor em dados independentes dos dados de treinamento. É importante não confundir os dados de teste com os dados de validação.

Partição dos dados

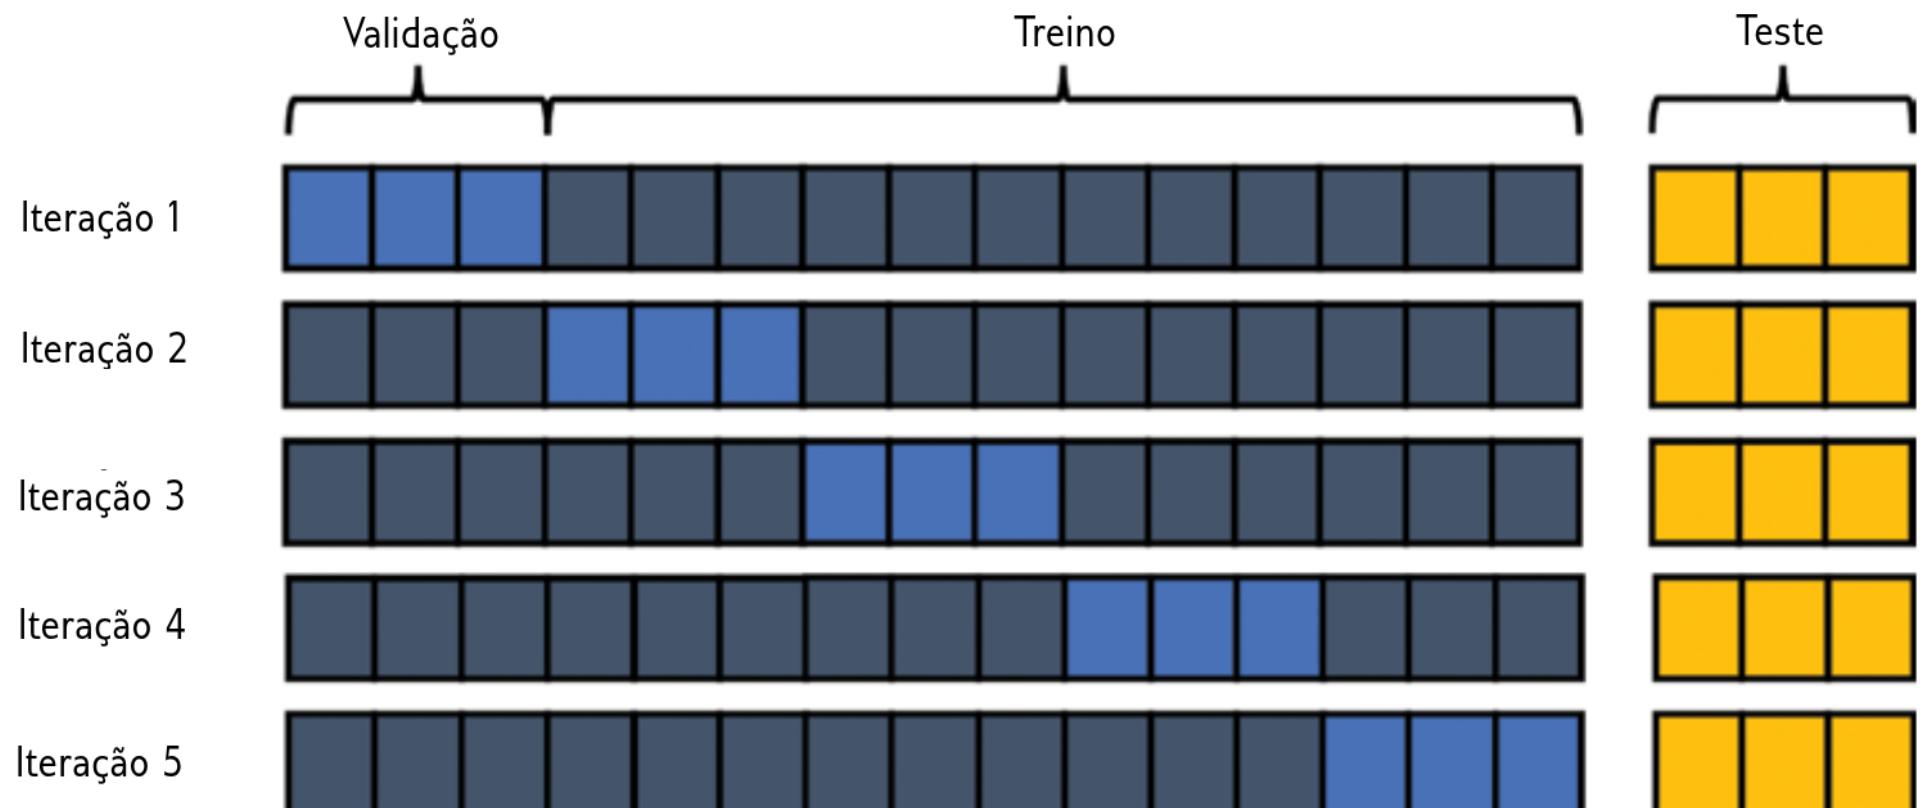
- No processo de validação e teste do modelo podemos usar dois métodos:
 - **Método de reserva (holdout method):** Reservamos partes do conjunto de dados original no início do desenvolvimento do modelo. Utilizamos o conjunto de validação para auxiliar no desenvolvimento do modelo e, em seguida, usamos o conjunto de teste para avaliar o desempenho do modelo final.
 - **Validação cruzada (cross-validation):** Envolve dividir os dados em várias partições (folds) e treinar/testar o modelo repetidamente usando diferentes partições. É particularmente útil em pequenos conjuntos de dados.

Método de reserva (holdout method)



Fonte: NWANGANGA & CHAPPLE (2020)

Validação cruzada (cross-validation)



Fonte: NWANGANGA & CHAPPLE (2020)

Exemplos

1. Considere cada um dos seguintes problemas de aprendizado de máquina. Seria melhor abordar o problema como um problema de classificação ou de regressão?
 - a. Prever o número de peixes capturados em uma viagem de pesca comercial.
 - b. Identificar prováveis adotantes de uma nova tecnologia.
 - c. Usar dados de clima e população para prever as taxas de aluguel de bicicletas.
 - d. Prever a melhor campanha de marketing a ser enviada a uma pessoa específica.

Exemplos

1. Você desenvolveu um algoritmo de aprendizado de máquina que avalia o risco de um paciente sofrer um ataque cardíaco (um evento positivo) com base em vários critérios diagnósticos. Como você descreveria cada um dos seguintes eventos?
 - a. Seu modelo identifica um paciente como provável de sofrer um ataque cardíaco, e o paciente sofre um ataque cardíaco.
 - b. Seu modelo identifica um paciente como provável de sofrer um ataque cardíaco, e o paciente não sofre um ataque cardíaco.
 - c. Seu modelo identifica um paciente como não provável de sofrer um ataque cardíaco, e o paciente não sofre um ataque cardíaco.
 - d. Seu modelo identifica um paciente como não provável de sofrer um ataque cardíaco, e o paciente sofre um ataque cardíaco.

Fim

